

电子商务搜索算法技术白皮书

(第一版)

淘宝搜索基础算法团队出品 编著



搜索事业部

搜索基础算法团队工作室·杭州

内 容 简 介

学习和总结近年来的一些新技术和结合电商场景的一些调研

目 录

第一章 序言	1
参考文献	3
第二章 业务问题所带来的技术挑战 @ 淘宝	4
参考文献	5
第三章 搜索工程和算法架构体系	6
3.1 工程架构	6
3.2 算法架构	6
3.3 工作流和数据流	6
参考文献	7
第四章 搜索词背后的技术	8
4.1 底纹推荐技术	8
4.2 查询词改写扩展技术	8
4.3 查询词意图预测技术	8
4.4 查询词图像化映射技术	9
4.5 AI4B 实战 @ 查询词图像化映射技术	9
参考文献	10

第五章 商品理解算法技术	11
5.1 商品销量预测与人气分模型	11
5.2 详情页满意度模型	11
5.3 用户浏览模型 & 用户点击满意度模型	11
5.4 网络效应分	11
5.5 商品簇模型	11
参考文献	12
第六章 用户理解算法技术	13
6.1 用户画像模型	13
6.2 Cohort 模型	13
参考文献	14
第七章 个性化搜索背后的核心技术	15
7.1 匹配学习	15
7.1.1 一阶人货匹配模型	15
7.1.2 高阶人货匹配模型	15
7.1.3 深度匹配模型	15
7.1.4 序列匹配模型	15
7.2 排序学习	16
7.3 展示学习	16
7.4 模型参数优化	16
参考文献	17
第八章 实时计算背后的核心技术	18
8.1 在线矩阵分解	18
8.2 在线 LTR	18
8.3 在线深度学习	18

8.4 大规模 WDL 模型	18
8.5 LR stacking on GBDT	19
参考文献	20
第九章 智能决策体系的建立	21
9.1 基于 MAB 的排序策略优化	21
9.2 基于 CMAB 的排序策略优化	21
9.3 基于强化学习的排序策略优化	21
9.4 级联式	21
参考文献	22
第十章 消费者权益智能分发核心技术	23
10.1 购物券/红包发放技术	23
参考文献	24
第十一章 迁移学习	25
11.1 营销场景下的深度迁移学习应用	25
参考文献	26
第十二章 对抗学习	27
12.1 GAN 的技术应用	27
参考文献	28
第十三章 反作弊技术 @ 淘宝	29
参考文献	30

第十四章 融入商业策略的流量优化探索	31
14.1 担保式流量分发系统的算法应用	31
14.1.1 基于 PID 控制器的流量分配模型	31
14.2 驱动供应链优化的流量分发系统设计	31
14.3 商业流量与免费流量有效平衡的流量分发系统	31
参考文献	32
第十五章 新技术视角下的搜索智能化思考	33
15.1 多智能体学习	33
15.2 强化迁移学习	33
15.3 终生学习	33
参考文献	34
参考文献	35

第一章 序言

学习目标与要求

淘宝搜索作为平台的一个重要联系买家和卖家的产品形态，由于其以下的特有属性，使其成为大数据智能化应用的最佳场景；1. 海量消费者与平台的互动行为 2. 海量商家在平台进行的商业活动行为 3. 海量的商品算法及模型在搜索和推荐系统领域占据统治地位之前，具有领域知识的专业运营和产品往往充当信息展示规则的缔造者，根据主观的判断和对市场的敏锐度来制定查询词背后的商品展示逻辑。“人工规则”的好处是容易理解和操控，坏处则不言而喻，随着平台规模的增大，简单规则无法精细的表达人货匹配的效率，并且容易被一些不良商家利用规则来扰乱市场秩序；实际上，早期的搜索和推荐系统也会运用一些基本的算法逻辑来保证信息匹配的正确性和人货匹配的公平性，基于传统搜索引擎技术的相关性模型，保证用户查询词语商品标题的有效匹配；基于商品成交与否的销售人气指数模型，保证有助于被消费者接受的商品得到更多的展示机会；另外还有一个就是系统为了保证让更多商家有机会得到展现，设置的按照虚拟下架周期为参考的轮播因子，即将下架的商品会得到相对较高的展示机会。

$$score(item) = 1 - \frac{ItemOffshelfTime - QueryTime}{secondsOfTwoweek} \times \left(\frac{docFound}{delta} \right)$$

2. 大规模机器学习时代随着平台规模的扩大，大规模商家入驻，积极的在平台

上打理店铺，发布商品，相对结构化的商品组织体系，类目结构，属性信息，基于商品为 key 的销量的累积，评论的累积，这些为更好的理解商品积累了重要的原始数据资料；消费者通过搜索产品的各级页面与平台的互动越来越频繁；数据的组织形成了以人为 key 的结构体系，反馈信号也得以在闭环系统中有效的流转；所有的这些都为理解用户积累了重要的数据资料。有效数据的积累为大规模运用机器学习技术解决问题提供了必要的土壤。

这方面各大互联网公司和科研机构，学校公开发表出来的有参考价值的工作有不少，典型的有价值工作，

搜索产品的典型技术课题，涉及 Query 理解，商品理解，个性化搜索

第一代搜索算法技术的一些弊端让它们已经不能适应现代化搜索技术体系的发展。

淘宝搜索算法技术演进之路可以分为四个阶段，如图所示：

参考文献

- [1] Bilinear+LinUcb 的个性化主题推荐, <http://www.atatech.org/articles/67847>
- [2] 依托搜索技术的个性化平台之路, <http://www.atatech.org/articles/13748>
- [3] 用户意图预估之实时意图篇, <http://www.atatech.org/article/detail/12636/152>
- [4] 知人知面需知心——论人工智能技术在推荐系统中的应用, <http://geek.csdn.net/news/detail/112318>
- [5] Google, Ad Click PredictionL a View from the trenches. pCTR 使用 LR, 通过 FTRL Proximal 算法实现在线模型更新, 频率学派, 写的很细致, 也有工程细节
- [6] Bing, Web-Scale Bayesian Click-through Rate Prediction for sponsored Search Advertising in Microsoft's Bing Search Engine。Online Bayesian Probit Regression, 贝叶斯学派, 涉及采样算法的模型
- [7] Facebook, Practical Lessones from Predicting Clicks on Ads Clicks on Ads at facebook。DT+LR。和 GBDT 非常类似, 不同之处在于用 LR 重新训练了每棵树投票的权重, 人气很旺的 xgboost, 在这一块也是做了优化, 利用二阶导数信息得到更快收敛的步长。缺点是处理不了高纬度特征, 处理连续值特征有优势。

第二章 业务问题所带来的技术挑战

@ 淘宝

学习目标与要求

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第三章 搜索工程和算法架构体系

学习目标与要求

3.1 工程架构

3.2 算法架构

3.3 工作流和数据流

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第四章 搜索词背后的技术

学习目标与要求

4.1 底纹推荐技术

底纹推荐技术, 实际上是实现一个从用户到 query 的映射模型 : $user \rightarrow query$

4.2 查询词改写扩展技术

查询词改写扩展技术, 转换为技术语言, 是一个完成从原始 query 到新 query 的映射模型 : $query \rightarrow query^*$

4.3 查询词意图预测技术

查询词意图预测技术, 意图可以类目 : $query \rightarrow category$

4.4 查询词图像化映射技术

4.5 AI4B 实战 @ 查询词图像化映射技术

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第五章 商品理解算法技术

学习目标与要求

5.1 商品销量预测与人气分模型

5.2 详情页满意度模型

@ 仁重

5.3 用户浏览模型 & 用户点击满意度模型

5.4 网络效应分

5.5 商品簇模型

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM
- [2] 流量个性化 v.s 商业化 - 双 11 珠峰项目中控算法, <http://www.atatech.org/articles/67132>
- [3] 确定性保证下流量分配在线全局优化策略, <http://www.atatech.org/articles/55983>
- [4] 搜索流量确定性项目总结, <http://www.atatech.org/articles/59651>
- [5] 网络效应分介绍, <https://www.atatech.org/articles/52962>
- [6] Unbiased Learning-to-Rank with Biased Feedback, <http://weibo.com/ttarticle/p/show?id=2309404077533346815648>

第六章 用户理解算法技术

学习目标与要求

6.1 用户画像模型

6.2 Cohort 模型

参考文献

[1]

第七章 个性化搜索背后的核心技术

学习目标与要求

综述性的东西，@ 三桐，@ 公达

7.1 匹配学习

7.1.1 一阶人货匹配模型

@ 公达 u_2i , u_2s , u_2b

7.1.2 高阶人货匹配模型

@ 公达 u_{2i2i} , u_{2s2i} , u_{2b2i}

7.1.3 深度匹配模型

7.1.4 序列匹配模型

7.2 排序学习

@ 元涵, @ 凌运, @ 龙楚

7.3 展示学习

个性化短标题 : @ 苏哲, @ 仁重

7.4 模型参数优化

@ 公达

参考文献

- [1] 淘宝搜索全链路有效行为量化模型 (UBM&UCM),
<http://www.atatech.org/articles/38550>
- [2] User Browsing Model 的实现与应用, <http://www.atatech.org/articles/23111>
- [3] 搜索个性化介绍, <http://www.atatech.org/articles/48548>

第八章 实时计算背后的核心技术

学习目标与要求

8.1 在线矩阵分解

@ 达卿, @ 席奈

8.2 在线 LTR

@ 凌运

8.3 在线深度学习

@ 京五

8.4 大规模 WDL 模型

8.5 LR stacking on GBDT

参考文献

- [1] 搜索双链路实时计算体系 @ 双 11 实战, <http://www.atatech.org/articles/44909>
- [2] 基于在线矩阵分解的淘宝搜索实时个性化, <http://www.atatech.org/articles/38646>
- [3] BP 如何运行, <http://www.offconvex.org/2016/12/20/backprop/>

第九章 智能决策体系的建立

学习目标与要求

9.1 基于 MAB 的排序策略优化

@ 帛逸

9.2 基于 CMAB 的排序策略优化

@ 公达, 凌运

9.3 基于强化学习的排序策略优化

@ 哲予, @ 达卿

9.4 级联式

参考文献

- [1] 实时策略寻优, <http://www.atatech.org/articles/44963>

第十章 消费者权益智能分发核心技术

学习目标与要求

10.1 购物券/红包发放技术

@ 达卿, @ 云志

参考文献

- [1] <http://www.atatech.org/articles/66486>, 双 11 搜索关键词红包：商家、用户与平台的三方共赢
- [2] 双 11 关键词红包：搜索链路新型互动性产品探索, <http://www.atatech.org/articles/44778>
- [3] 淘宝外卖智能补贴算法, <http://www.atatech.org/articles/72599>

第十一章 迁移学习

学习目标与要求

11.1 营销场景下的深度迁移学习应用

@ 一尘, @ 海凯

参考文献

- [1] Gan 导读, <http://weibo.com/ttarticle/p/show?id=2309404060390806926698>

第十二章 对抗学习

学习目标与要求

12.1 GAN 的技术应用

参考文献

- [1] Gan 导读, <http://weibo.com/ttarticle/p/show?id=2309404060390806926698>

第十三章 反作弊技术 @ 淘宝

学习目标与要求

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第十四章 融入商业策略的流量优化探索

学习目标与要求

14.1 担保式流量分发系统的算法应用

14.1.1 基于 PID 控制器的流量分配模型

@ 仁重

14.2 驱动供应链优化的流量分发系统设计

@ 仁重

14.3 商业流量与免费流量有效平衡的流量分发系统

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM
- [2] 流量个性化 v.s 商业化 - 双 11 珠峰项目中控算法, <http://www.atatech.org/articles/67132>
- [3] 确定性保证下流量分配在线全局优化策略, <http://www.atatech.org/articles/55983>
- [4] 搜索流量确定性项目总结, <http://www.atatech.org/articles/59651>

第十五章 新技术视角下的搜索智能化思考

学习目标与要求

15.1 多智能体学习

15.2 强化迁移学习

15.3 终生学习

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

参考文献

- [1] Dimitri P. Bertsekas, Dynamic Programming and Optimal Control, Vol. II, 4th Edition: Approximate Dynamic Programming