

电子商务搜索算法技术白皮书

(第一版)

淘宝搜索基础算法团队出品 编著



搜索事业部

搜索基础算法团队工作室·杭州

内 容 简 介

各类主要的互联网服务，包括搜索、广告、推荐、等等，它们的一个典型共同特征，就是利用不断增强的计算处理能力和日益丰富的资源种类，对百万乃至上百亿量级以上的超大规模数据进行分析 and 挖掘，数据维度包罗万象，比如网页内容、用户行为、时间序列、等等，去充分理解消费者需求，定位供给端的品类和质量，建立一个良性的买家和卖家的公平交易平台；

淘宝搜索作为平台的一个重要联系买家和卖家的产品形态，由于其以下的特有属性，使其成为大数据智能化应用的最佳场景；

海量消费者与平台的互动行为

买家和卖家的公平交易平台

海量商家在平台进行的商业活动行为

本书将围绕淘宝搜索智能化体系的演进历程进行系统化阐述，如何依托于工程架构体系的逐步完善，逐步实现从简单人工运营加简单算法规则的时代，发展成为阿里电商平台辅助消费者与商品（卖家）的互动更加趣味化和效率化的智能中枢，不仅仅可以从海量用户行为数据中寻找行为规律，结构化行为序列，并从规律中预测结果，更重要的是给出有效的流量中心化和去中心化的投放决策，从而实现消费者，卖家，平台三者社会福利的最大化。淘宝的搜所和推荐发展到今天，正在从智能的依靠机器学习能力解决业务问题，向更高效的从不确定性中探索目标的学习 + 决策的能力进化。

目 录

第一章 序言	1
1.1 算法演进之路	1
1.1.1 人工 + 弱算法时代	2
1.1.2 大规模机器学习时代	2
1.1.3 准人工智能时代	3
1.1.4 人工智能时代	3
1.2 评估体系	3
1.3 技术体系进展	3
参考文献	4
第二章 业务问题所带来的技术挑战 @ 淘宝	6
2.1 业务问题的思考 @ 淘宝搜索	6
2.1.1 动态性	6
2.1.2 全链路优化	7
2.1.3 商业属性	8
2.1.4 垂直化	8
2.2 技术挑战 @ 业务问题	9
2.2.1 算法模型	9
2.2.2 工程技术	10
2.2.3 效果评估	10

参考文献	11
第三章 搜索工程和算法架构体系	12
3.1 工程架构	12
3.2 算法架构	13
3.3 评估指标及 ab 系统	13
3.4 工作流和数据流	13
参考文献	14
第四章 搜索词背后的技术	15
4.1 底纹推荐技术	15
4.2 查询词改写扩展技术	15
4.3 查询词意图预测技术	15
4.4 查询词图像化映射技术	16
4.5 深层语义匹配技术	16
4.6 AI4B 实战 @ 查询词图像化映射技术	16
参考文献	17
第五章 商品理解算法技术	18
5.1 商品销量预测与人气分模型	18
5.2 详情页满意度模型	18
5.3 用户浏览模型 & 用户点击满意度模型	18
5.4 网络效应分	18
5.5 商品簇模型	18
5.6 AI4B 实战	18
参考文献	19

第六章 用户理解算法技术	20
6.1 用户画像模型	20
6.2 Cohort 模型	20
6.3 AI4B 实战	20
参考文献	21
第七章 个性化搜索背后的核心技术	22
7.1 匹配学习	25
7.1.1 一阶人货匹配模型	25
7.1.2 高阶人货匹配模型	25
7.1.3 深度匹配模型	26
7.1.4 序列匹配模型	26
7.2 排序学习	26
7.2.1	26
7.3 展示学习	26
7.4 模型参数优化	26
7.5 AI4B 实战	26
参考文献	27
第八章 实时计算背后的核心技术	28
8.1 在线矩阵分解	28
8.2 在线 LTR	28
8.3 在线深度学习	28
8.4 大规模 WDL 模型	28
8.5 LR stacking on GBDT	29
8.6 AI4B 实战	29
参考文献	30

第九章 智能决策体系的建立	31
9.1 基于 MAB 的排序策略优化	31
9.2 基于 CMAB 的排序策略优化	31
9.3 基于强化学习的排序策略优化	31
9.4 级联式	31
9.5 AI4B 实战	32
参考文献	33
第十章 消费者权益智能分发核心技术	34
10.1 购物券/红包发放技术	34
参考文献	35
第十一章 迁移学习	36
11.1 营销场景下的深度迁移学习应用	36
参考文献	37
第十二章 对抗学习	38
12.1 GAN 的技术应用	38
参考文献	40
第十三章 反作弊技术 @ 淘宝	41
参考文献	42
第十四章 融入商业策略的流量优化探索	43
14.1 商业变现模式对比	43
14.2 担保式流量分发系统的算法应用	43
14.2.1 基于 PID 控制器的流量分配模型	44

14.3 驱动供应链优化的流量分发系统设计	44
14.4 商业流量与免费流量有效平衡的流量分发系统	44
参考文献	45
第十五章 新技术视角下的搜索智能化思考	46
15.1 多智能体学习	46
15.2 强化迁移学习	46
15.3 终生学习	46
参考文献	47
参考文献	48

第一章 序言

学习目标与要求

1.1 算法演进之路

从 pc 互联网到移动互联网，阿里巴巴电商平台一路高歌猛进，数据规模，计算能力都发生了天翻地覆的变化；如图 1 所示，

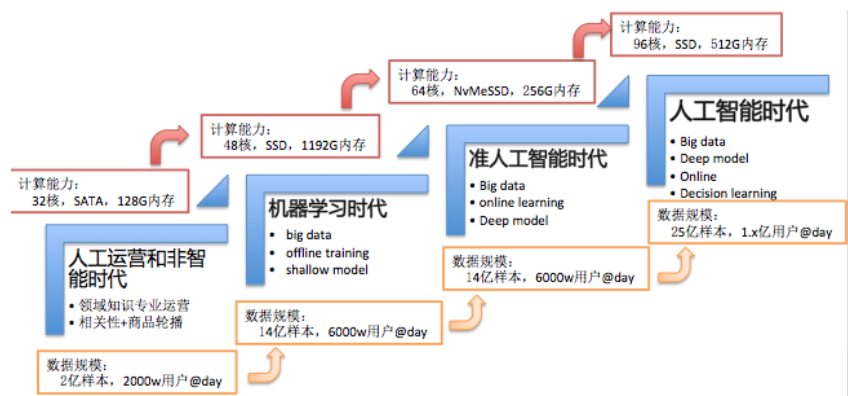


图 1.1: 搜索智能化体系演进图

1.1.1 人工 + 弱算法时代

这个时代的关键词：**规则 + 轮播**

算法及模型在搜索和推荐系统领域占据统治地位之前，具有领域知识的专业运营和产品往往充当信息展示规则的制定者，根据主观的判断和对市场的敏锐度来制定查询词背后的商品展示逻辑。“人工规则”的好处是容易理解和操控，坏处则不言而喻，随着平台规模的增大，简单规则无法精细的表达人货匹配的效率，并且容易被一些不良商家利用规则来扰乱市场秩序；实际上，早期的搜索和推荐系统也会运用一些基本的算法逻辑来保证信息匹配的正确性和人货匹配的公平性，基于传统搜索引擎技术的相关性模型，保证用户查询词语商品标题的有效匹配；基于商品成交与否的销售人气指数模型，保证有助于被消费者接受的商品得到更多的展示机会；另外还有一个就是系统为了保证让更多商家有机会得到展现，设置的按照虚拟下架周期为参考的轮播因子，即将下架的商品会得到相对较高的展示机会。

$$score(item) = 1 - \frac{ItemOffshelfTime - QueryTime}{secondsOfTwoweek} \times \left(\frac{docFound}{delta}\right)$$

这个时代遗留下来几个关键问题需要解决：

1.1.2 大规模机器学习时代

这个时代的关键词：**big data, offline + shallow model**

随着平台规模的扩大，大规模商家入驻，积极的在平台上打理店铺，发布商品，相对结构化的商品组织体系，类目结构，属性信息，基于商品为 key 的销量的累积，评论的累积，这些为更好的理解商品积累了重要的原始数据资料；消费者通过搜索产品的各级页面与平台的互动越来越频繁；数据的组织形成了以人为 key 的结构体系，反馈信号也得以在闭环系统中有效的流转；所有的这些都为理解用户积累了重要的数据资料。有效数据的积累为大规模运用机器学习技术解决问题提供了必要的土壤。

这方面各大互联网公司和科研机构，学校公开发表出来的有参考价值的工作有不少，典型的有价值工作，logistic regression, gbd t ;

1.1.3 准人工智能时代

这个时代关键词：**big data, online, deep model**

1.1.4 人工智能时代

这个时代的关键词：**big data, online, deep model, decision learning**

淘宝搜索算法技术演进之路可以分为四个阶段，如图所示：

1.2 评估体系

1.3 技术体系进展

recency-sensitive ranking location-sensitive ranking

参考文献

- [1] Bilinear+LinUcb 的个性化主题推荐, <http://www.atatech.org/articles/67847>
- [2] 依托搜索技术的个性化平台之路, <http://www.atatech.org/articles/13748>
- [3] 用户意图预估之实时意图篇, <http://www.atatech.org/article/detail/12636/152>
- [4] 知人知面需知心——论人工智能技术在推荐系统中的应用, <http://geek.csdn.net/news/detail/112318>
- [5] Google, Ad Click PredictionL a View from the trenches. pCTR 使用 LR, 通过 FTRL Proximal 算法实现在线模型更新, 频率学派, 写的很细致, 也有工程细节
- [6] Bing, Web-Scale Bayesian Click-through Rate Prediction for sponsored Search Advertising in Microsoft's Bing Search Engine. Online Bayesian Probit Regression, 贝叶斯学派, 涉及采样算法的模型
- [7] Facebook, Practical Lessones from Predicting Clicks on Ads Clicks on Ads at facebook. DT+LR. 和 GBDT 非常类似, 不同之处在于用 LR 重新训练了每棵树投票的权重, 人气很旺的 xgboost, 在这一块也是做了优化, 利用二阶导数信息得到更快收敛的步长。缺点是处理不了高纬度特征, 处理连续值特征有优势。

-
- [8] 我所经历的大数据平台发展史 (三): 互联网时代 • 上篇,
<http://www.infoq.com/cn/articles/the-development-history-of-big-data-platform-paet02>,
 - [9] Fast and Reliable Online Learning to Rank for Information Retrieval,
<https://khofm.files.wordpress.com/2013/04/thesis-katja-hofmann-online-learning.pdf>
 - [10] Dawei Yin, etc..., Ranking Relevance in Yahoo Search, KDD'16
 - [11] C.J.C. Burges, FromRankNettoLambdaRanktoLambdaMART: An overview,
Technical report, Microsoft Research 2010
 - [12] Z. Cao, T. Qin, etc..., Learningtorank: from pairwise approach to listwise approach, ICML'07
 - [13] A. Dong, Y. Chang, etc..., Towards recency ranking in web search. In WSDM'10.

第二章 业务问题所带来的技术挑战

@ 淘宝

学习目标与要求

2.1 业务问题的思考 @ 淘宝搜索

淘宝的搜索平台是致力于提供一个一个买家和卖家的公平交易平台；作为一个公平的市场调节员，调整供需平衡，为卖家引导潜在的兴趣用户，以提升其ROI (return on investment)，为用户提供满足其需求 (user intent) 的商品；商业流量下的搜索自然带有其特有的技术特点：

2.1.1 动态性

网页搜索的对象的是分布于各类网站发布的网页，从索引单元上对比，数量上是绝对要远远大于商品搜索的对象集合，如果把每个商品展示页当成是淘宝网站的普通网页的化，表象上讲，商品页面的信息集合应该是网页搜索对象集合的一个子集；网页搜索中的基本对象也存在网页更新，然而淘宝搜索的商品库具有更强的动态性，宝贝的循环搁置，新卖家加入，卖家新商品的推出，价

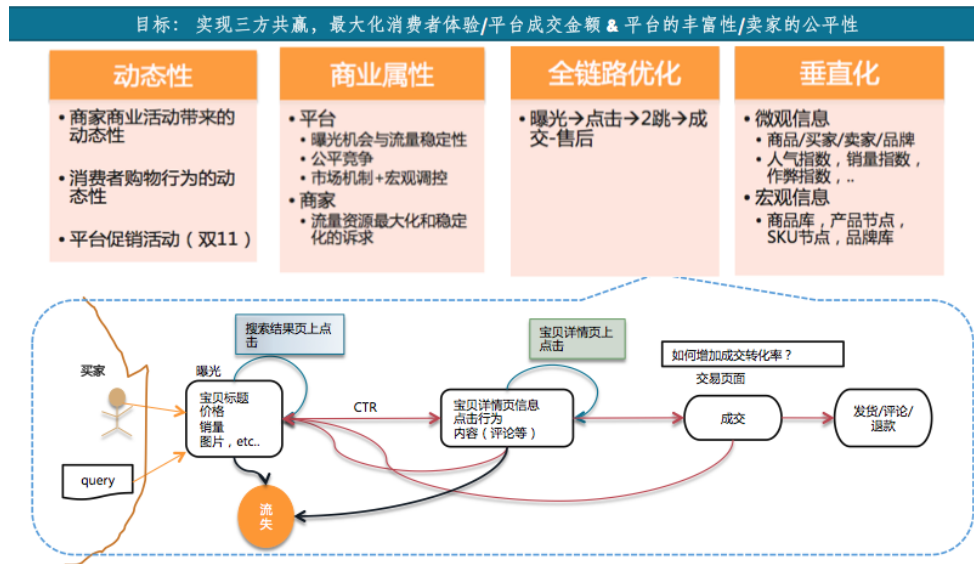


图 2.1: 电商搜索特性

格的调整，标题的更新，旧商品的下架，换季商品的促销，上下架，降价，宝贝图片的更新，销量的变化，卖家等级的提升，商品竞争程度的提升等，都需要淘宝的商品搜索引擎在第一时间捕捉到变化，并及时反映到索引结构中的相应信息单元，而最终的排序环节，这些变化也会动态的融入排序因子，带来排序的动态调整；因此对于商品搜索引擎，要求建立高效的索引更新体系，适应商品类目体系，倒排索引结构，匹配机制的召回逻辑，以及应对商品排序信息及时生效的 cache 分层机制；

2.1.2 全链路优化

众所周知，相比类似百度这样的网页搜索平台，一个明显的差异是，淘宝搜索平台拥有网购消费者从查询到完成目标商品订单，这样一条完整的行为数据闭合式链路；因此对于用户的一次查询的满意度衡量绝不能止于搜索结果页上看到一个标题相关的商品而发生了点击来判别，post-click 之后的商品详情页上的行为，甚至于进入 post-pay 之后的评论信息都应该成为度量某商品对于某次

查询 (query) 的满意度影响因子；因此，全链路的行为建模会是淘宝搜索体系相比于网页搜索的重要差异之处；既然谈到这点了，再多☒嗦两句，京东也是一家做电子商务的公司，也有着不小的规模，那么如何来看淘宝搜索与京东搜索在全链路优化上的差异呢？从京东模式来看，post-pay 环节，由于销售，物流仓储的自营性，可以认为是无差异竞争的；而对于淘宝来说，售后的服务，发货速度，以及纠纷退款等环节是取决于商家与消费者之间的互动来决定的，差异性不言而喻，因此淘宝搜索有必要建立 post-pay 环节的排序度量因子；

2.1.3 商业属性

电子商务平台的搜索自然具备商业流量的根本属性，商家希望所经营商品通过得到足够的曝光而带来成交；因此，流量资源 (曝光) 也就成了商家必争之地。搜索排序体系的白盒化和可解释性自然是至关重要。淘宝搜索的 ranking, 更接近于一个带约束的优化问题，而不是一个简单的排序，优化的目标是最大化平台的成交金额；而约束则是卖家流量分配的诉求；这个环节的涉及到的课题也是电商平台最复杂之处，我会在下面集中阐述下我的一些观点；

2.1.4 垂直化

电子商务搜索属于 vertical search 范畴，相比于网页搜索，对于平台上内容的结构化梳理，以及商业平台上积累的买家，卖家和商品关系数据的挖掘都有更高的要求；因此需要建立 micro analysis 和 macro analysis 双位一体的搜索内容加工体系，宏观分析层面指的是：除了目前已经积累并广泛运用的 5 级类目之外，完善的商品库建设，spu 节点，sku 节点，品牌库等，都是必不可少的；微观分析层面则从商品的人气指数，销量指数，作弊指数等角度给出商品自身质量的度量信息；使得搜索结果能够为消费者提供，不仅仅停留在标题相关层面的服务，可以通过合理的宏观分析带来的数据结构化，实现高效的结果查询，通过细致的微观分析，保证优质的商品优先展示给消费者；

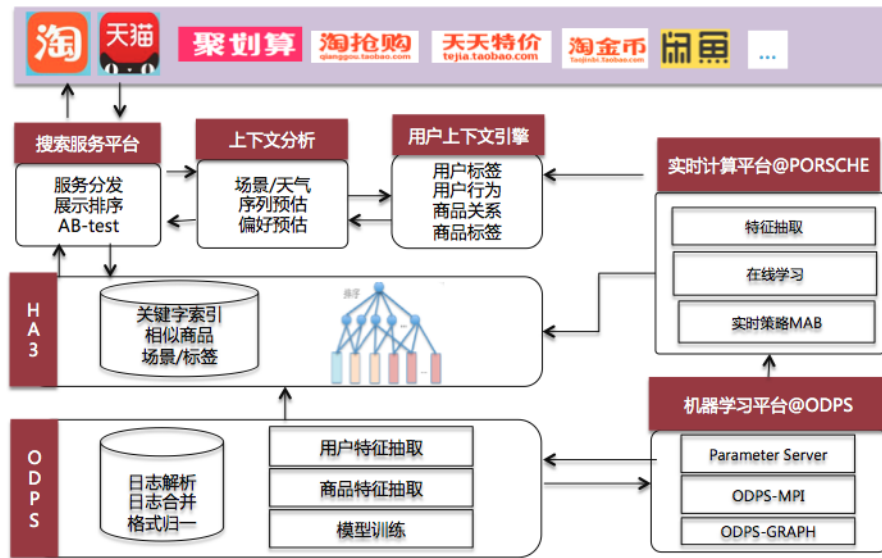


图 2.2: 智能化助力商业产品

2.2 技术挑战 @ 业务问题

2.2.1 算法模型

像众多互联网企业一样，大数据环境下，基于用户行为建模所面临的技术挑战很多，大家耳熟能详的点列举如下：

投放逻辑带来的数据 bias 对行为建模的影响

用户行为数据的稀疏性

因果关系的模糊性

用户行为的时效

行为个性化和非个性化 unified ranking

Cold start modeling

多样性与精确性的 tradeoff (过度个性化)

长短期个性化融合

2.2.2 工程技术

随着数据规模的指数级增长，完成复杂数据建模对于工程技术体系的挑战也是不言而喻：

千亿行为和关系数据存储、实时更新和查询

翻页陷阱

Cache 机制

分级实时体系 (数天/小时/秒/ms)

2.2.3 效果评估

效果评估是保证体系迭代朝正向发展的关键保障。

模型正确性评估

Ab 体系下分群评估

社会化评测

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第三章 搜索工程和算法架构体系

学习目标与要求

3.1 工程架构

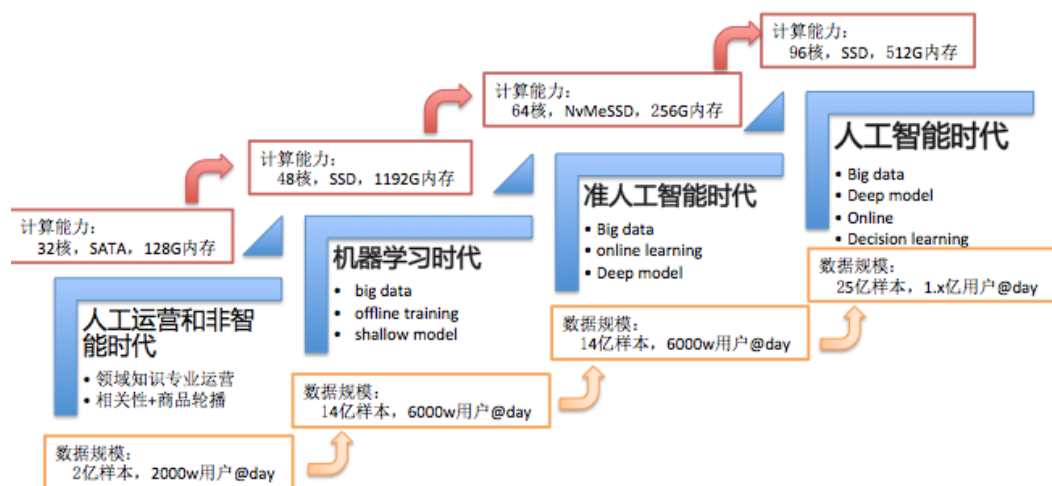


图 3.1: 工程架构图

3.2 算法架构

大规模机器学习体系如下图所示：

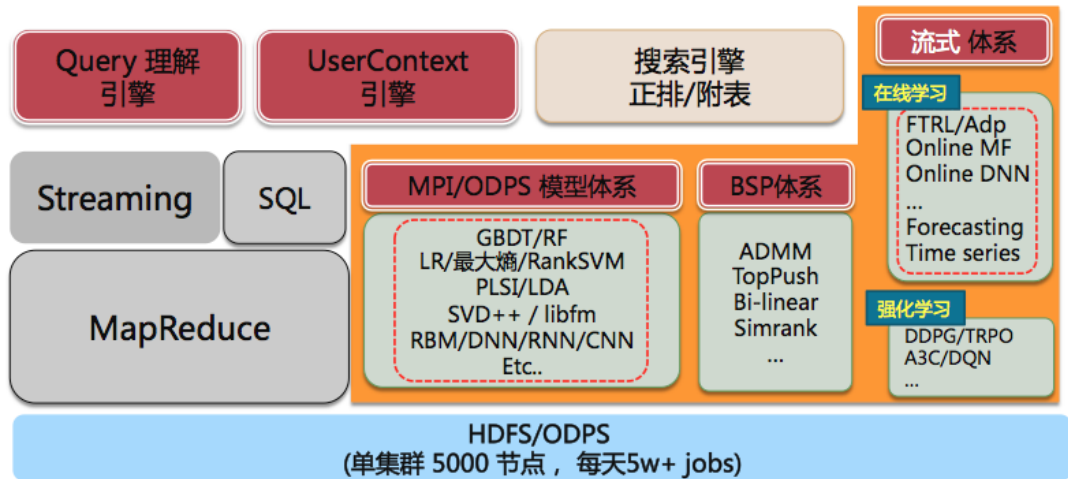


图 3.2: 大规模机器学习 @ 淘宝搜索

3.3 评估指标及 ab 系统

我们平台上所关心的指标有：

uv 转化率: $cvr = \frac{buy_{uv}}{uv}$

uv 点击率: $ctr = \frac{ip_{vv}}{uv}$

客单价:

GMV:

3.4 工作流和数据流

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第四章 搜索词背后的技术

学习目标与要求

4.1 底纹推荐技术

底纹推荐技术, 实际上是实现一个从用户到 query 的映射模型 : $user \rightarrow query$

4.2 查询词改写扩展技术

查询词改写扩展技术, 转换为技术语言, 是一个完成从原始 query 到新 query 的映射模型 : $query \rightarrow query^*$

4.3 查询词意图预测技术

查询词意图预测技术, 意图可以类目 : $query \rightarrow category$

4.4 查询词图像化映射技术

4.5 深层语义匹配技术

4.6 AI4B 实战 @ 查询词图像化映射技术

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第五章 商品理解算法技术

学习目标与要求

5.1 商品销量预测与人气分模型

5.2 详情页满意度模型

@ 仁重

5.3 用户浏览模型 & 用户点击满意度模型

5.4 网络效应分

5.5 商品簇模型

5.6 AI4B 实战

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM
- [2] 流量个性化 v.s 商业化 - 双 11 珠峰项目中控算法, <http://www.atatech.org/articles/67132>
- [3] 确定性保证下流量分配在线全局优化策略, <http://www.atatech.org/articles/55983>
- [4] 搜索流量确定性项目总结, <http://www.atatech.org/articles/59651>
- [5] 网络效应分介绍, <https://www.atatech.org/articles/52962>
- [6] Unbiased Learning-to-Rank with Biased Feedback, <http://weibo.com/ttarticle/p/show?id=2309404077533346815648>

第六章 用户理解算法技术

学习目标与要求

6.1 用户画像模型

6.2 Cohort 模型

6.3 AI4B 实战

参考文献

[1]

第七章 个性化搜索背后的核心技术

学习目标与要求

进入正题之前首先谈一谈个性化方向后续需要关注的几个点，搜索个性化时至今日，已经成为互联网网站的技术标配，虽然业界取得了一些成绩，但挑战仍然存在；

首先来看看为什么要作个性化，搜索中引入个性化的目的是什么每天有近 30000 个查询“连衣裙”的消费者，query + “user context”的查询逻辑能够实现不同的消费群体看到不同商品投放结果，实现平台上人-货匹配在搜索流量上的个性化细分，比如说，“肥胖”的女性查询结果里面更多的展现宽松风格的商品，而消费能力高的消费者更多的展现高品位的大牌商品，从而达到流量投放效率的最大化；总而言之，目的是两个：a). 提升流量匹配效率：具体表现在购物路径上的效果指标；b). 改善宽泛 query 下得流量集中性，提升宽泛 query 下不同人群看到的展示商品不同，而带来成交商品和点击商品的丰富性；总而言之：对于广大消费者，由于个性化能够细分搜索意图，拟合个体偏好，有助于更快捷找到需求；

弄清楚了搜索个性化的目的，下面想来澄清几个问题：

1. 个性化并不是定制化

Customization：实现的境界是 You are what you say you are？或者说，平台按照系统理解的用户 profile，并按照某种特定个性化规则去投放，即是，实现

you are what the system thinks you are. 对于针对用户的查询结果的信息展示是局限在 explicit 的“feature”层面，比方说，按照购买力匹配规则，按照品牌偏好规则等等；定制化的好处确实能够在某种程度上带来强的个性化体验，但是带来的伤害也是不言而喻；而 Personalization 是：根据用户行为所挖掘的偏好信息来进行展示商品的投放，即是，实现 you are what you click on and what you buy；对于针对用户的查询结果的商品展示是基于“内容和数据”层面；不去刻意的假设用户的行为是由于某个特定维度（人口统计类特征，偏好类特征，人群特征）造成的，消费者点击或成交行为的发生，是所有个性化信息的综合表现；为什么我在这里先提出这个问题，因为经常听到的很多关于，目前线上个性化效果不尽人意的反馈，在这里，也不去刻意回避我们自己的问题，个性化数据，模型的覆盖率，准确性和时效性等都需要进一步的优化和改进；然而，对于那些为了增强所谓的个性化体验而实行的规则式匹配逻辑，都是极其不科学的做法，对于消费者而言，他们需要的是找到一个符合他 / 她需求的商品，而个性化体验强弱与否并非是最最终的目的，我相信的是，消费者不会因为我们预测到他的性别，购买力，偏好的品牌就做出点击或购买的决策，个性化是我们系统实现高效的【人 - 货】匹配效率的手段，并非是消费者的购物诉求；在这里也请从事个性化方面的运营，产品，甚至算法同学能时刻理解这点；

2. 不要陷入活跃/资深用户的悖论

正常的用户无论其活跃与否，都不会愿意浪费时间去填写所谓的友好的交互式表单来帮助系统去理解他们，从而得到更好的个性化体验；他们关注的是展示商品整体是否满足他们的需求，而不会去刻意的由于商品的某个维度匹配了他/她得某个偏好而做出最终的选择；这里列举一个曾经的产品设计，在搜索结果页，给出用户可以定制的个性化偏好交互界面，希望消费者能告诉我们他们的个性化 profile，出发点是好的，结局大家懂的；

3. 个性化 explore 的重要性

随着个性化元素在搜索全链路的渗透，从 query 的个性化标注，海选的个性化召回，精排中的个性化排序因子，以及个性化 rerank，个性化展示，使得最终呈现给用户的内容取决于系统底层根据用户历史行为所挖掘的个性化特征，人口统计学维度，兴趣点偏好维度，session 级别实时特征，过度的“user specific

historical behaviour driven“的个性化投放，会使得用户逐渐丧失对展示结果的新鲜感，并且视野变得越来越狭窄，进而使得底层的用户数据模型丧失自我修复和自我扩展能力；因此一个完整的个性化体系，必须考虑 explore 机制的设计环节；

4. 个性化评估的方法论

要想推动个性化效果的正向迭代，首先需要建立起合理的效果评估体系；然而这仍然是一个很大的问题，学术界流行的准确率，召回率，F1 值，AUC，RMSE，等都有很大的局限性，这一层面的评估，只能保证数据模型的正确性；而在实际工作中，这些指标上的不一定能保证线上效果的收益；因此我们需要第二层次的评估手段，来看个性化算法效果。实现个性化的投放效果，是系统层面的主动而为，而且并没有去引导消费者端在一次搜索看到展示结果后，做出选择。因此在消费者不知情情况下，消费者的行为反馈可以用来作为个性化效果评估的一个手段。对于已经上线的个性化特征，需要部署相应的统计分析模块，在 ABtest 机制下，监控各个特征的覆盖率，以及覆盖流量下的点击率，转化率等；虽然无法直接统计到这些特征对于点击和转化带来的精确影响，但是通过追踪高权重 user 的体验 - 点击率，2 跳率，转化率等，能够了解这些特征的影响趋势，及早发现问题；这里特别强调下，采用高权重 user 的行为数据来分析的原因是，高权重用户意味着是活跃用户，意味着行为丰富，而这类用户的个性化特征的表现会更有代表性；最后，我也来谈谈对于针对个性化效果的社会化评测的意见和想法，便于理解，就以用户购买力为例来讲讲，为了更好来把握该维度数据的有效性，经常利用的手段是社会化评测来给定一些查询下，看看展示结果里面展示商品的价格是否符合评测者的价格偏好，从表象上看，似乎没有问题，然而，这里面确有一个本质上的问题，我们限定了这些参与评测人得判断角度，只关注商品价格，并给出满意与否的结论，而在实际购物场景下，用户对于商品满意与否接受与否，并不是只限定在价格本身，因此这样的评测还是有一定的局限性；我个人的观点，还是去真实的模拟线上的判断环境，不去刻意要求消费者去关注某个固定的维度，只是给出 site by site 的结果，让用户判断哪边展示的商品更符合他的口味，当然，这不同 site 的展示结果的差异，背后只是某个维度的个性化带来的影响，这样去评测，才更加客观；总结一句话，

就是众包评测的关键是，希望参与者能做出客观的反馈，不应该做任何主观性的引导；

5. 个性化体系对于系统和框架的影响

在搜索场景下实现个性化的效果，就需要去建模分析【query-user-商品】三元组构成下得海量数据分析，数据是极端稀疏的，算法时间和空间的复杂性，都对于系统能很好的支持分布和并行的数据分析和建模能力提出了很高的要求；另外，用户偏好的时效性，也需要我们能够实现增量，实时计算能力，个性化的实施，使得传统引擎依赖的性能优化利器，cache 机制无法施展手脚，因此对于引擎的创新性改造也提出了更高的要求；另外，个性化数据的挖掘都是存在不确定性的，如何来设计一套能够保证误差不会累积的算法体系，也就是说需要建立一套数据自我修复的实时反馈体系，来保证由消费者端实时获取的客观反馈数据参与到个性化投放环节来保证模型的自我修复能力快于数据误差的传播速度；这样才能保证数据产生的价值形成良性的循环，构成大数据生态体系；

个性化是一种解决“长尾需求”的方式，“长尾理论”说的是用户需求集中度越来越低，用户和用户之间不一样，我们如何来区分这种不一样？个性化搜索就是融合推荐元素，以实现：用户个体需求主导的“pull”式搜索加平台以数据驱动的方式对用户进行“push”式相关信息推送；

综述性的东西，@ 三桐，@ 公达

7.1 匹配学习

7.1.1 一阶人货匹配模型

@ 公达 $u2i$, $u2s$, $u2b$

7.1.2 高阶人货匹配模型

@ 公达 $u2i2i$, $u2s2i$, $u2b2i$

7.1.3 深度匹配模型

7.1.4 序列匹配模型

7.2 排序学习

@ 元涵, @ 凌运, @ 龙楚

7.2.1

7.3 展示学习

个性化短标题 : @ 苏哲, @ 仁重

7.4 模型参数优化

@ 公达

7.5 AI4B 实战

参考文献

- [1] 淘宝搜索全链路有效行为量化模型 (UBM&UCM),
<http://www.atatech.org/articles/38550>
- [2] User Browsing Model 的实现与应用, <http://www.atatech.org/articles/23111>
- [3] 搜索个性化介绍, <http://www.atatech.org/articles/48548>

第八章 实时计算背后的核心技术

学习目标与要求

8.1 在线矩阵分解

@ 达卿, @ 席奈

8.2 在线 LTR

@ 凌运

8.3 在线深度学习

@ 京五

8.4 大规模 WDL 模型

8.5 LR stacking on GBDT

8.6 AI4B 实战

参考文献

- [1] 搜索双链路实时计算体系 @ 双 11 实战, <http://www.atatech.org/articles/44909>
- [2] 基于在线矩阵分解的淘宝搜索实时个性化, <http://www.atatech.org/articles/38646>
- [3] BP 如何运行, <http://www.offconvex.org/2016/12/20/backprop/>

第九章 智能决策体系的建立

学习目标与要求

9.1 基于 MAB 的排序策略优化

@ 帛逸

9.2 基于 CMAB 的排序策略优化

@ 公达，凌运

9.3 基于强化学习的排序策略优化

@ 哲予，@ 达卿

9.4 级联式

9.5 AI4B 实战

参考文献

- [1] 实时策略寻优, <http://www.atatech.org/articles/44963>
- [2] 强化学习博客, <http://blog.exbot.net/?s=>

第十章 消费者权益智能分发核心技术

学习目标与要求

在我们的业务场景下，经常会遇到这样的问题，有限的资源下，在尽可能满足多宿主资源诉求的前提下最大化资源的利用效率，比方说一下问题：

广告展示场景：

包裹分配：

消费者权益发放：

10.1 购物券/红包发放技术

@ 达卿，@ 云志

参考文献

- [1] <http://www.atatech.org/articles/66486>, 双 11 搜索关键词红包：商家、用户与平台的三方共赢
- [2] 双 11 关键词红包：搜索链路新型互动性产品探索, <http://www.atatech.org/articles/44778>
- [3] 淘宝外卖智能补贴算法, <http://www.atatech.org/articles/72599>
- [4] 大数据下线性最优化问题 solver 介绍, <https://www.atatech.org/articles/69242?commentId=115358comment-115358>

第十一章 迁移学习

学习目标与要求

11.1 营销场景下的深度迁移学习应用

@ 一尘, @ 海凯

参考文献

- [1] Gan 导读, <http://weibo.com/ttarticle/p/show?id=2309404060390806926698>


第十二章 对抗学习

学习目标与要求

12.1 GAN 的技术应用

在我们实际大数据环境中，我们需要从数据中挖掘出基本的结构化信息，从而可以帮助我们有效构造样本，解决一些传统监督学习所无法解决的问题；比方说，正样本覆盖率低，负样本缺失，模型 overfitting，鲁棒性不够等等；生成式模型的目的是找到一个函数可以最大的似然数据的真实分布；通常我们用 $f(X : \theta)$ 来表示这样的函数，找到一个使生成的数据最像真实数据的过程就是一个 MLE 的过程。问题是：当数据的分布比较复杂时，简单的函数无法表达样本空间；现在通过深度网络结构可以表达一个更加复杂的函数，但是训练过程成为了关键。基于 sampling 的训练过程显示不是高效的；早年 graphical model 会采用变分推断方法；还有今年出现的对抗学习方法；GAN 相关技术的演变如下图所示：

最经典的 GAN 模型，由 Ian Goodfellow 提出，先从一个简单的分布中采样一个噪声信号，然后经过生成函数后映射到我们想去拟合的数据分布 x_g 。生成的数据和真实数据都会输入到一个识别网络 D，识别网络通过判别输出一个标量，表示数据来自真实数据的概率。在实现上，要求 G 和 D 都是可微分函数，



$$\min_G \left[\max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] \right]$$

图 12.1: 标准 GAN 算法示意图

可以用多层神经网络来实现；后半部分是模型训练中的目标函数。从公式上看，类似于 CrossEntropy，注意到 D 是 $P(\mathbf{X}_{\text{data}})$ 的近似。对于 D 来说，要尽量使公式最大化（识别能力强），而对于 G 又想使其最小。整个训练过程是一个迭代过程，但是在迭代中，对 D 的优化又是内循环。生成模型可以发挥价值的场所：

特征表示

强化学习中的探索

逆强化学习

迁移学习

参考文献

- [1] Gan 导读, <http://weibo.com/ttarticle/p/show?id=2309404060390806926698>
- [2] John Glover, Modeling documents with generative adversarial networks, workshop on adversarial training, NIPS 2016, Barcelona, Spain

第十三章 反作弊技术 @ 淘宝

学习目标与要求

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

第十四章 融入商业策略的流量优化探索

学习目标与要求

14.1 商业变现模式对比

14.2 担保式流量分发系统的算法应用

类型	缺点
CPC 模式	点击率的预估准确性高，使得平台的流量利用效率高，卖家的流量确定性高
CPM 模式	
固定佣金模式	
返利模式	

14.2.1 基于 PID 控制器的流量分配模型

@ 仁重

14.3 驱动供应链优化的流量分发系统设计

@ 仁重

14.4 商业流量与免费流量有效平衡的流量分发系统

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM
- [2] 流量个性化 v.s 商业化 - 双 11 珠峰项目中控算法, <http://www.atatech.org/articles/67132>
- [3] 确定性保证下流量分配在线全局优化策略, <http://www.atatech.org/articles/55983>
- [4] 搜索流量确定性项目总结, <http://www.atatech.org/articles/59651>

第十五章 新技术视角下的搜索智能化思考

学习目标与要求

15.1 多智能体学习

15.2 强化迁移学习

15.3 终生学习

参考文献

- [1] C. Burges, T. Shaked, etc., Learning to rank using gradient descent. In Proceedings of the 22nd international conference on machine learning, ACM

参考文献

- [1] Dimitri P. Bertsekas, Dynamic Programming and Optimal Control, Vol. II, 4th Edition: Approximate Dynamic Programming